

Análisis del brillo de cielo nocturno durante la Navidad de Vigo

Víctor Tilve

2025-09-05

Primer análisis de los datos.

En primer lugar se indica la carpeta donde se encuentran los archivos en formatos Turtle y RDF/XML para cargarlos. Muchos ya fueron tratados mediante consultas SPARQL con la herramienta GraphDB para llegar aquí con toda la información necesaria y requerida. Después se define la consulta SPARQL cuyo resultado será transformado en un dataframe de R.

```
library(readr)
library(ggplot2)
library(dplyr)

##
## Attaching package: 'dplyr'

## The following objects are masked from 'package:stats':
##
##   filter, lag

## The following objects are masked from 'package:base':
##
##   intersect, setdiff, setequal, union

library(rdflib)

rdf_data <- "/media/victor/1FPB-COTARE/Cousas/TFM-IA/TFM-trabajo/00.CousasDefinitivas/EventoLucesNadal"

#Función para procesar un solo archivo RDF/XML
#Mucho ojo con los prefijos porque en el final / o # debe coincidir con el grafo
procesar_rdf <- function(file_path) {
  rdf <- rdf_parse(file_path, format = "rdfxml")
  consulta <- '
PREFIX sosa: <http://www.w3.org/ns/sosa/>
PREFIX rdf: <http://www.w3.org/1999/02/22-rdf-syntax-ns#>
PREFIX ex: <http://example.org#>

SELECT ?observacion ?sensor ?fecha ?valor ?noche ?luna ?finSemana ?lucesNavidad
WHERE {
  ?observacion rdf:type sosa:Observation ;
    sosa:madeBySensor ?sensor ;
    sosa:resultTime ?fecha ;
    sosa:hasSimpleResult ?valor ;
    ex:esNocheAstronomica ?noche ;
    ex:hayBrilloLuna ?luna ;
    ex:finDeSemana ?finSemana ;
```

```

        ex:lucesNavidadEncendidas ?lucesNavidad ;
    }'

resultado <- rdf_query(rdf, consulta)
df <- as.data.frame(resultado)

df$valor <- as.numeric(df$valor)
df$noche <- tolower(df$noche) == "true"
df$luna <- tolower(df$luna) == "true"
df$finSemana <- tolower(df$finSemana) == "true"
df$fecha <- as.POSIXct(df$fecha, format="%Y-%m-%dT%H:%M:%S", tz="UTC")

return(df)
}

```

En esta parte del código se decide si se leen todos los archivos de la carpeta indicada anteriormente o mediante expresiones regulares se ponen las condiciones que se decidan. En este caso se cargan cuatro archivos RDF/XML con el resultado de una consulta de SPARQL que recupera todas las observaciones realizadas con los fotómetros tras su enriquecimiento con información variada: si hay brillo de Luna, estación del año y si es fin de semana o no. Se hace así porque un único archivo pesa más de 350MB y R se reinicia al procesarlo. Sin embargo, dividido en 4 partes sí consigue cargar los datos.

```

# Lista de archivos RDF en la carpeta
archivos <- list.files(rdf_data, pattern = "\\..xml$",
                      full.names = TRUE)

# Procesar y combinar todos los data.frames
todos_los_datos <- bind_rows(lapply(archivos, procesar_rdf))

```

Se hace ahora un criba de los datos seleccionando aquellos de interés para el estudio, que son dentro de la noche astronómica y sin Luna, y se eliminan los datos atípicos.

```

datos_filtrados <- subset(todos_los_datos, noche == TRUE & luna == FALSE)
rm(todos_los_datos)
datos_filtrados$solo_fecha <- as.Date(datos_filtrados$fecha) # solo la fecha (YYYY-MM-DD)
datos_filtrados$solo_hora <- format(datos_filtrados$fecha, format = "%H:%M:%S") # solo la hora
datos_filtrados <- subset(datos_filtrados, valor > 0)
#Valores atípicos

lim_inf <- quantile(datos_filtrados$valor, 0.01, na.rm = TRUE)
lim_sup <- quantile(datos_filtrados$valor, 0.99, na.rm = TRUE)
datos_filtrados <- subset(datos_filtrados, valor >= lim_inf & valor <= lim_sup)

#Valores atípicos

Q1 <- quantile(datos_filtrados$valor, 0.25, na.rm = TRUE)
Q3 <- quantile(datos_filtrados$valor, 0.75, na.rm = TRUE)
IQR_valor <- Q3 - Q1

lim_inf <- Q1 - 1.5 * IQR_valor
lim_sup <- Q3 + 1.5 * IQR_valor

outliers <- datos_filtrados %>%
  filter(valor < lim_inf | valor > lim_sup)

```

```
datos_filtrados <- subset(datos_filtrados, valor >= lim_inf & valor <= lim_sup)

#Etiqueta
datos_filtrados$etiqueta_sensor <- sub(".*#([_]+[_]+).*", "\\1", datos_filtrados$sensor)
```

Para las horas se toman en formato c'iclico para evitar los saltos que hay con el cambio de día. Para documentarse sobre la codificaci'on c'iclica horaria se pueden consultar los enlaces:

<https://www.kaggle.com/code/avanwyk/encoding-cyclical-features-for-deep-learning>

<https://medium.com/@axelazara6/why-we-need-encoding-cyclical-features-79ecc3531232>

```
# Codificar la hora decimal como variable circular
datos_filtrados <- datos_filtrados %>%
  mutate(
    hora_decimal = as.numeric(format(fecha, "%H")) + as.numeric(format(fecha, "%M")) / 60,
    hora_minuto = format(fecha, "%H:%M")
  )

datos_filtrados$hora_sin <- sin(2 * pi * datos_filtrados$hora_decimal / 24)
datos_filtrados$hora_cos <- cos(2 * pi * datos_filtrados$hora_decimal / 24)
```

Patrón Navidad

En este apartado se va a analizar si existe un patrón de luces de Navidad


```
# Paquetes
library(dplyr)
library(ggplot2)

# ----- Boxplots DS vs FS para cada sensor -----
sensor_col = "etiqueta_sensor"
value_col = "valor"
time_col = "fecha"
lucesNavidad_col = "lucesNavidad"

# Etiquetas bonitas
datos_filtrados$lucesNavidad_lbl <- factor(ifelse(datos_filtrados$lucesNavidad,
  "Encendidas", "Apagadas"),
  levels = c("Encendidas", "Apagadas"))

# Gráfico facetado por sensor
g <- ggplot(datos_filtrados, aes(x = lucesNavidad_lbl,
  y = .data[[value_col]],
  fill = lucesNavidad_lbl)) +
  geom_boxplot(outlier.alpha = 0.2, outlier.size = 0.7) +
  stat_summary(fun = mean, geom = "point", shape = 23, size = 1.8,
    fill = "white") +
  facet_wrap(vars(.data[[sensor_col]]), scales = "free_y") +
  scale_fill_brewer(palette = "Set2", guide = "none") +
  labs(title = "Distribución del brillo por sensor (luces Navidad encendidas vs apagadas)",
    x = NULL, y = "Brillo (mag/arcsec²)") +
  theme_minimal(base_size = 11) +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
```

g



Parece que en las Illas Cíes no se aprecian diferencias importantes entre apagadas y encendidas; sin embargo en el Porto de Vigo sí.

Test de permutación

El test de permutaciones es un test de significancia estadística para el estudio de diferencias entre grupos desarrollado por Ronald Fisher y E.J.G. Pitman en 1930.

```
library(dplyr)
library(lubridate)

##
## Attaching package: 'lubridate'
## The following objects are masked from 'package:base':
##
##   date, intersect, setdiff, union

set.seed(100)

df_noches <- datos_filtrados %>%
  group_by(sensor, fecha, lucesNavidad, lucesNavidad_lbl) %>%
  summarise(mediana = median(valor, na.rm = TRUE), .groups = "drop")

permutacion_test <- function(x_on, x_off, B = 1500, stat = function(a,b) median(a) - median(b)) {
```

```

x_on <- x_on[is.finite(x_on)]
x_off <- x_off[is.finite(x_off)]
obs <- stat(x_on, x_off)
pooled <- c(x_on, x_off)
n_on <- length(x_on)

perms <- replicate(B, {
  idx <- sample(seq_along(pooled))
  stat(pooled[idx][1:n_on], pooled[idx][-1:n_on])
})
p_val <- mean(abs(perms) >= abs(obs))
list(stat_observada = obs, p_value = p_val)
}

# Ejecuta por sensor:
results_perm <- df_noches %>%
  group_by(sensor) %>%
  summarise({
    on <- mediana[lucesNavidad]
    off <- mediana[!lucesNavidad]
    if (length(on) > 3 && length(off) > 3) {
      r <- permutacion_test(on, off, B = 1500)
      tibble(dif_mediana = r$stat_observada, p_value = r$p_value,
             n_medidas_on = length(on), n_medidas_off = length(off))
    } else {
      tibble(dif_mediana = NA_real_, p_value = NA_real_, n_noches_on = length(on), n_noches_off = length(off))
    }
  }) %>%
  arrange(p_value)

print(results_perm)

```

```

## # A tibble: 2 x 5
##   sensor                                dif_mediana p_value n_medidas_on n_medidas_off
##   <chr>                                <dbl>     <dbl>         <int>         <int>
## 1 http://example.org#SQM_IllasCi~    0.0870  0.0193           4826           9649
## 2 http://example.org#SQM_PortoVi~   -0.0360  0.427            4827           9884

```

Según estos resultados, la variación de brillo es significativa en Illas Cíes y no lo es en Porto de Vigo; pero esto no casa con el diagrama de cajas hecho anteriormente. A continuación se profundiza en el análisis estratificando por día.

```

library(dplyr)
library(purrr)
library(tidyr)
library(stats)

set.seed(100)

# --- Preparación de datos ---
df0 <- datos_filtrados %>%
  transmute(
    sensor = as.character(sensor),
    rt     = as.POSIXct(fecha, tz = "UTC"),
    valor  = as.numeric(valor),

```

```

    luces = as.logical(lucesNavidad),
    fecha = as.Date(fecha, tz = "UTC")
  ) %>%
  filter(!is.na(sensor), !is.na(rt), !is.na(valor), !is.na(luces))

# sensores
sensores <- c("SQM_PortoVigo", "SQM_IllasCies")

# --- (A) Test de permutación estratificado por fecha ---
test_perm_por_fecha <- function(d, n_perm = 5000) {
  d1 <- d %>%
    group_by(fecha) %>%
    filter(any(luces == TRUE) & any(luces == FALSE)) %>%
    ungroup()

  if (nrow(d1) == 0) {
    return(tibble(
      dif_mediana = NA_real_, p_value = NA_real_,
      n_on = sum(d$luces), n_off = sum(!d$luces),
      n_dias = 0
    ))
  }

  stat_global <- function(z) {
    med_on <- median(z$valor[z$luces], na.rm = TRUE)
    med_off <- median(z$valor[!z$luces], na.rm = TRUE)
    med_on - med_off
  }

  T_obs <- stat_global(d1)

  perm_once <- function() {
    z <- d1 %>%
      group_by(fecha) %>%
      mutate(luces_perm = sample(luces)) %>% # permuta SOLO dentro de cada fecha
      ungroup()
    med_on <- median(z$valor[z$luces_perm], na.rm = TRUE)
    med_off <- median(z$valor[!z$luces_perm], na.rm = TRUE)
    med_on - med_off
  }

  T_perm <- replicate(n_perm, perm_once())
  p_two <- mean(abs(T_perm) >= abs(T_obs))

  tibble(
    dif_mediana = T_obs,
    p_value = p_two,
    n_on = sum(d1$luces),
    n_off = sum(!d1$luces),
    n_dias = dplyr::n_distinct(d1$fecha)
  )
}

```

```

res_perm <- map_dfr(sensores, function(pat) {
  d <- df0 %>% filter(grepl(pat, sensor))
  out <- test_perm_por_fecha(d, n_perm = 500)
  mutate(out, sensor = pat, .before = 1)
})

print(res_perm)

## # A tibble: 2 x 6
##   sensor      dif_mediana p_value  n_on n_off n_dias
##   <chr>          <dbl>    <dbl> <int> <int>  <int>
## 1 SQM_PortoVigo    0.202    0.984  4827  4115   110
## 2 SQM_IllasCies    0.0860   0.132  4826  4058   110

# --- (B) Wilcoxon pareado sobre medianas DIARIAS ---
wilcoxon_por_fecha <- function(d) {
  per_dia <- d %>%
    group_by(fecha, luces) %>%
    summarise(med = median(valor, na.rm = TRUE), .groups = "drop") %>%
    pivot_wider(names_from = luces, values_from = med, names_prefix = "luces_") %>%
    filter(!is.na(luces_TRUE), !is.na(luces_FALSE)) %>%
    mutate(diff = luces_TRUE - luces_FALSE)

  if (nrow(per_dia) == 0) {
    return(list(n_dias = 0, diff_mediana = NA_real_, wilcox = NULL))
  }

  test <- wilcox.test(per_dia$diff, mu = 0, alternative = "two.sided", exact = FALSE)
  list(
    n_dias = nrow(per_dia),
    diff_mediana = median(per_dia$diff, na.rm = TRUE),
    wilcox = test
  )
}

res_wilcox <- map(sensores, function(pat) {
  d <- df0 %>% filter(grepl(pat, sensor))
  out <- wilcoxon_por_fecha(d)
  tibble(
    sensor = pat,
    n_dias = out$n_dias,
    mediana_dif_diaria = out$diff_mediana,
    W = if (!is.null(out$wilcox)) unname(out$wilcox$statistic) else NA_real_,
    p_value = if (!is.null(out$wilcox)) out$wilcox$p.value else NA_real_
  )
}) %>% list_rbind()

print(res_wilcox)

## # A tibble: 2 x 5
##   sensor      n_dias mediana_dif_diaria      W p_value
##   <chr>        <int>          <dbl> <dbl>    <dbl>
## 1 SQM_PortoVigo    110          -0.200  2547    0.132
## 2 SQM_IllasCies    110           0.228  3702    0.0529

```

El resultado son p-valores altos en el test de permutaciones y en Wilcoxon las datos de Illas Cíes se acercan a un p-valor significativo, manteniendo así la contradicción tanto respecto a los diagramas de caja como a la lógico, ya que el SQM de Porto de Vigo está en el centro de la ciudad, donde están las luces instaladas. Parece conveniente calcular los datos estadísticos habituales para ver qué sucede:

```
df_luces <- subset(datos_filtrados,etiqueta_sensor="SQM_PortoVigo",lucesNavidad == TRUE)
```

```
## Warning: In subset.data.frame(datos_filtrados, etiqueta_sensor = "SQM_PortoVigo",
##   lucesNavidad == TRUE) :
##   extra argument 'etiqueta_sensor' will be disregarded
```

```
v1<-df_luces$valor
```

```
# --- Cálculo de estadísticos ---
```

```
Q1  <- as.numeric(quantile(v1, .25))
med  <- as.numeric(quantile(v1, .5))
Q3  <- as.numeric(quantile(v1, .75))
minv <- min(v1)
maxv <- max(v1)
IQRv <- Q3 - Q1
meanv <- mean(v1)
sdv  <- sd(v1)
```

```
estadisticos <- c(Q1,med,Q3,minv,maxv,IQRv,meanv,sdv)
```

```
df_luces <- subset(datos_filtrados,etiqueta_sensor="SQM_PortoVigo",lucesNavidad == FALSE)
```

```
## Warning: In subset.data.frame(datos_filtrados, etiqueta_sensor = "SQM_PortoVigo",
##   lucesNavidad == FALSE) :
##   extra argument 'etiqueta_sensor' will be disregarded
```

```
v2<-df_luces$valor
```

```
# --- Cálculo de estadísticos ---
```

```
Q1  <- as.numeric(quantile(v2, .25))
med  <- as.numeric(quantile(v2, .5))
Q3  <- as.numeric(quantile(v2, .75))
minv <- min(v2)
maxv <- max(v2)
IQRv <- Q3 - Q1
meanv <- mean(v2)
sdv  <- sd(v2)
```

```
estadisticos <- rbind2(estadisticos,c(Q1,med,Q3,minv,maxv,IQRv,meanv,sdv))
```

```
colnames(estadisticos) <- c("Q1","med","Q3","minv","maxv","IQRv","meanv","sdv")
rownames(estadisticos) <- c("PortoVigo-ON", "PortoVigo-OFF")
```

```
estadisticos
```

```
##           Q1    med    Q3   minv   maxv  IQRv   meanv    sdv
## PortoVigo-ON 16.431 17.982 20.106 13.892 21.609 3.675 18.07815 2.056271
## PortoVigo-OFF 16.426 18.079 19.996 13.899 21.640 3.570 18.14676 1.969882
```

Se confirma con estos datos que efectivamente no hay cambios significativos a nivel global en el brillo de fondo de cielo medido con el SQM instalado en el Porto de Vigo con y sin luces de Navidad. Igualmente se hace un último intento con un algoritmo de entrenamiento.

“Contrafactual” sencillo por sensor

Con este algoritmo se entrena un modelo (ARIMA/ETS/loess) solo con noches sin luces, posteriormente se predice en noches con luces y se analiza el sesgo medio de los residuos.

```
library(dplyr)
library(forecast)

## Registered S3 method overwritten by 'quantmod':
##   method      from
##   as.zoo.data.frame zoo

set.seed(100)
contrafactual <- function(dd) {
  # Serie a 10 min promediada por fecha
  serie <- dd %>% arrange(fecha)
  # Entrena con OFF
  train <- serie %>% filter(!lucesNavidad)
  test  <- serie %>% filter( lucesNavidad)
  if (nrow(train) < 200 || nrow(test) < 50) return(NA_real_)
  fit <- auto.arima(train$valord)
  fc <- forecast(fit, h = nrow(test))
  mean(test$valord - as.numeric(fc$mean), na.rm = TRUE)
}

bias_por_sensor <- datos_filtrados %>%
  group_by(sensor) %>%
  summarise(sesgo_medio_on_vs_cf = contrafactual(cur_data_all()))

## Warning: There was 1 warning in `summarise()`.
## i In argument: `sesgo_medio_on_vs_cf = contrafactual(cur_data_all())`.
## i In group 1: `sensor =
##   "http://example.org#SQM_IllasCies_CIE_42.213900_-8.906000"`.
## Caused by warning:
## ! `cur_data_all()` was deprecated in dplyr 1.1.0.
## i Please use `pick()` instead.

print(bias_por_sensor)
```

```
## # A tibble: 2 x 2
##   sensor                                     sesgo_medio_on_vs_cf
##   <chr>                                     <dbl>
## 1 http://example.org#SQM_IllasCies_CIE_42.213900_-8.906000 -0.866
## 2 http://example.org#SQM_PortoVigo_VIG_42.241670_-8.727587 -0.195
```

Los dos sesgos medios son negativos, por lo que durante el encendido de las luces el cielo tiene menos magnitud, es decir, más brillo (peor oscuridad) que su contrafactual sin luces.

En términos lineales, ya que la magnitud es logarítmica, estos resultados dicen que el cielo de Cíes es 2,22 veces más brillante con luces, mientras que el de Vigo es 1,2 veces más brillante. Siguen siendo